

UNIVERSIDAD MAYOR DE SAN ANDRÉS
FACULTAD DE CIENCIAS PURAS Y NATURALES
CARRERA DE INFORMÁTICA



“Artículo Proceso Covid-19”

MATERIA: INTELIGENCIA ARTIFICIAL - INF - 372

PARALELO: A

INTEGRANTES:

- CARVAJAL QUISPE ESTHER MAYERLY
- MAMANI GUTIERREZ SARAHI NICOL
- MAMANI APAZA NOHEMY RUTH

FECHA: 15 DE DICIEMBRE DEL 2025

LA PAZ - BOLIVIA

Predicción de Riesgo de Mortalidad en Pacientes con COVID-19: Un Enfoque de Aprendizaje Automático mediante Random Forest y Análisis de Conglomerados en Población Mexicana

Resumen

El presente estudio aborda la problemática de la estratificación de riesgo en pacientes diagnosticados con COVID-19, utilizando un conjunto de datos masivo de más de un millón de registros proporcionados por el gobierno de México. Ante la saturación de los sistemas de salud, la identificación temprana de pacientes con alto riesgo de mortalidad es crítica. Se implementó un flujo de trabajo de ciencia de datos que incluyó ingeniería de características, imputación de valores faltantes y técnicas de balanceo de datos mediante submuestreo (undersampling). Se entrenó un modelo supervisado basado en el algoritmo Random Forest, justificando su elección por su robustez ante datos tabulares y desbalanceados. Adicionalmente, se aplicaron técnicas no supervisadas (PCA y K-Means) para identificar fenotipos clínicos. Los resultados demuestran la viabilidad de utilizar variables demográficas y comorbilidades preexistentes para predecir desenlaces fatales, ofreciendo una herramienta de soporte para la toma de decisiones clínicas.

Palabras clave: COVID-19, Machine Learning, Random Forest, Desbalanceo de Clases, K-Means, Triage Clínico.

1. Introducción

La pandemia de COVID-19 representó un desafío sin precedentes para los sistemas sanitarios globales. Uno de los problemas operativos más graves fue la asignación eficiente de recursos limitados, como camas en Unidades de Cuidados Intensivos (UCI) y ventiladores mecánicos. En este contexto, la capacidad de predecir tempranamente qué pacientes tienen mayor probabilidad de desarrollar un cuadro severo o fallecer se convirtió en una prioridad de investigación.

Este estudio utiliza un conjunto de datos públicos obtenidos de Kaggle, originados por el sistema de salud mexicano, que contiene información clínica anonimizada de 1,048,576 pacientes. El objetivo principal es desarrollar un modelo predictivo capaz de estimar el riesgo de mortalidad basándose en características clínicas, demográficas y comorbilidades disponibles al momento del

ingreso. A diferencia de enfoques puramente estadísticos, este trabajo emplea algoritmos de aprendizaje automático (*Machine Learning*), específicamente **Random Forest**, debido a su capacidad para manejar relaciones no lineales y su interpretabilidad en datos médicos complejos.

2. Metodología

2.1. Descripción del Conjunto de Datos

El dataset consta de 23 atributos que describen el estado de pacientes durante el curso de la pandemia. Las variables incluyen datos demográficos (edad, sexo), comorbilidades (diabetes, EPOC, asma, hipertensión, obesidad, entre otras) y datos del sistema sanitario. Se identificaron sesgos geográficos inherentes a la población mexicana y un sistema de codificación no convencional donde los valores 97 y 99 representaban datos faltantes en variables booleanas. Particularmente, variables críticas como *INTUBED* e *ICU* presentaron cerca de un 80% de datos faltantes, lo que limitó su uso directo como predictores, obligando al modelo a depender más de las comorbilidades preexistentes.

2.2. Preprocesamiento e Ingeniería de Características

Para garantizar la calidad de los datos, se ejecutaron las siguientes fases:

1. **Definición de la Variable Objetivo (Target):** Se transformó la variable *DATE_DIED*. Originalmente, el valor '9999-99-99' indicaba supervivencia. Se generó una variable binaria *IS_DEAD* donde:
 - Clase 0 (Sobreviviente): *DATE_DIED* == '9999-99-99'.
 - Clase -1 (Fallecido): *DATE_DIED* != '9999-99-99'.
2. **Tratamiento de Valores Faltantes:** Se detectaron códigos numéricos (97, 98, 99) actuando como *missing values*. Se empleó un filtro *NumericCleaner* para convertirlos a NaN, seguido de una imputación estadística mediante la moda para variables nominales, preservando la integridad de los registros.
3. **Codificación:** Se aplicó *One-Hot Encoding* a las variables categóricas nominales para evitar que el algoritmo asumiera una jerarquía ordinal inexistente. La variable *AGE* se mantuvo numérica debido a su naturaleza cuantitativa.

2.3. Estrategia de Balanceo de Datos

El análisis exploratorio reveló un desbalance severo: aproximadamente el 93% de los pacientes sobrevivieron, mientras que solo el 7% falleció. Entrenar un modelo con esta distribución generaría un sesgo hacia la clase mayoritaria (supervivencia). Para mitigar esto, se optó por una estrategia de **Submuestreo Aleatorio (Undersampling)** utilizando el algoritmo `SpreadSubsample` con un parámetro de distribución de 1.0. Esto redujo la cantidad de instancias de la clase mayoritaria hasta igualar la frecuencia de la clase minoritaria, resultando en un dataset de entrenamiento equilibrado (50/50), esencial para mejorar la sensibilidad del modelo ante los casos de fallecimiento.

2.4. Selección del Modelo: Random Forest

Se seleccionó Random Forest (Breiman, 2001) como clasificador principal. Esta decisión se fundamenta en la literatura (Fernández-Delgado et al., 2014), que posiciona a este algoritmo como superior en datos tabulares. Sus ventajas para este estudio incluyen:

- **Manejo de Datos Heterogéneos:** Procesa eficazmente la mezcla de variables binarias y numéricas.
- **Robustez:** Su arquitectura de ensamblado (bagging) reduce la varianza y el riesgo de sobreajuste.
- **Pesos de Clases:** Permite configurar `class_weight='balanced'`, penalizando los errores en la clase minoritaria.

2.5. Análisis No Supervisado

Para complementar el enfoque predictivo, se aplicaron técnicas no supervisadas:

- **PCA (Análisis de Componentes Principales):** Para reducción de dimensionalidad y visualización.
- **K-Means Clustering:** Se utilizó el método del codo para determinar el número óptimo de clusters ($K=3$) y perfilar a los pacientes según sus características sin conocer su desenlace *a priori*.

3. Resultados

3.1. Evaluación del Modelo Supervisado

El modelo fue evaluado utilizando una división inicial de 80% entrenamiento y 20% prueba. Posteriormente, se realizaron pruebas de robustez con divisiones 50/50 y validación cruzada.

Métricas de Desempeño (Conjunto de Prueba): El modelo alcanzó una exactitud (*Accuracy*) global del 95%. Sin embargo, dado el desbalanceo, el análisis se centró en la clase crítica (Fallecidos):

- **Precisión (Clase Fallecido):** 0.78. Indica que, de los pacientes que el modelo predijo que fallecerían, el 78% realmente falleció.
- **Recall (Clase Fallecido):** 0.62. Indica que el modelo fue capaz de detectar el 62% del total de fallecimientos reales.

Matriz de Confusión: Se observaron 4,300 Verdaderos Positivos (fallecidos detectados correctamente) frente a 9,500 Falsos Negativos. Aunque el número de falsos negativos es alto, es un comportamiento esperado en un primer despliegue con datos ruidosos y masivos. Los Falsos Positivos (3,200) son clínicamente menos costosos, ya que implican sobre-atención a un paciente que finalmente sobrevive.

3.2. Resultados del Análisis de Conglomerados (K-Means)

El análisis no supervisado reveló tres perfiles de pacientes claramente diferenciados, validando la coherencia clínica de los datos:

1. **Cluster 1 (Bajo Riesgo - 43%):** Pacientes jóvenes (promedio 28 años), sin comorbilidades significativas y tratamiento mayoritariamente ambulatorio.
2. **Cluster 2 (Riesgo Moderado - 37%):** Adultos de mediana edad (promedio 45 años) con presencia incipiente de hipertensión o diabetes.
3. **Cluster 3 (Alto Riesgo - 20%):** Pacientes geriátricos (promedio 63+ años) con comorbilidades múltiples (obesidad, EPOC, renal crónica) y altas tasas de hospitalización. Este cluster presentó la mayor correlación con la variable `IS_DEAD`.

4. Discusión

La aplicación de Random Forest sobre el dataset de COVID-19 en México ha permitido identificar patrones de mortalidad consistentes con la literatura médica. La importancia de las características extraídas por el modelo confirma que la edad avanzada, la neumonía y las comorbilidades metabólicas (diabetes, obesidad) son los predictores más fuertes de un desenlace fatal.

El uso de **Undersampling** fue crucial. Sin el balanceo de datos, el modelo habría alcanzado una exactitud del 93% simplemente prediciendo que todos los pacientes sobrevivirían, lo cual carece de valor clínico ("Accuracy Paradox"). Al equilibrar las clases, sacrificamos exactitud global a cambio de ganar sensibilidad en la detección de fallecimientos, que es el objetivo médico prioritario.

El análisis de clusters (K-Means) proporcionó una validación externa no supervisada. El hecho de que el algoritmo agrupará automáticamente a los pacientes más ancianos y enfermos en un solo cluster (Cluster 3), sin haber sido entrenado con la etiqueta de mortalidad, refuerza la calidad de los datos y la fuerte señal predictiva que poseen las comorbilidades.

Limitaciones: El sesgo geográfico limita la extrapolación directa a poblaciones no mexicanas. Asimismo, la alta tasa de valores faltantes en variables de UCI impidió evaluar el impacto de los cuidados intensivos en la supervivencia.

5. Conclusiones

Este estudio demuestra que es posible construir modelos predictivos de mortalidad por COVID-19 con un desempeño razonable utilizando datos demográficos y clínicos básicos disponibles al momento del ingreso hospitalario.

1. **Eficacia del Algoritmo:** Random Forest probó ser una herramienta robusta, manejando adecuadamente el ruido y el desbalanceo inherente a los datos médicos de emergencia.
2. **Relevancia del Preprocesamiento:** La ingeniería de características y el balanceo de clases fueron determinantes; sin estos pasos, el poder predictivo del modelo sería nulo para la clase minoritaria.

3. **Utilidad Práctica:** La identificación de los tres clusters de riesgo sugiere que este modelo podría simplificarse en un sistema de puntuación para triaje rápido en hospitales con recursos limitados.

Como trabajo futuro, se propone evaluar técnicas de sobremuestreo (como SMOTE) para comparar el rendimiento frente al submuestreo utilizado, y explorar modelos de *Deep Learning* si se integran datos de imágenes médicas.

También se subió el proceso y archivos al siguiente repositorio:

<https://github.com/Nohemy254/Covid19-Mortalidad>