

Proyecto Final IA

UNIVERSIDAD MAYOR DE SAN ANDRÉS

FACULTAD DE CIENCIAS PURAS Y NATURALES

CARRERA DE INFORMÁTICA



MATERIA: INTELIGENCIA ARTIFICIAL - INF - 372

PARALELO: A

INTEGRANTES:

- CARVAJAL QUISPE ESTHER MAYERLY
- MAMANI GUTIERREZ SARAH NICOL
- MAMANI APAZA NOHEMY RUTH

FECHA: 15 DE DICIEMBRE DEL 2025

Descripción Detallada del Dataset COVID-19

El conjunto de datos, obtenido de Kaggle y proporcionado por el gobierno mexicano, contiene información médica anonimizada de más de un millón de pacientes con COVID-19.

Origen y Sesgos

Los datos provienen de México, lo que introduce un sesgo geográfico. Presenta un sistema de codificación no convencional (valores 97 y 99 para datos faltantes) y una gran cantidad de valores ausentes en variables específicas, especialmente en pacientes ambulatorios.

Características


Incluye 1,048,576 instancias y 23 atributos únicos. Las variables abarcan desde datos demográficos (edad, sexo) hasta condiciones preexistentes (diabetes, asma), tratamientos (intubado, UCI) y resultados clínicos (fallecimiento).

Variables del Dataset y Desafíos

El dataset se compone de variables numéricas, categóricas binarias y nominales, además de algunas especiales que requieren atención.

Variables Clave

- **Numérica:** AGE (Edad)
- **Binarias:** SEX, PNEUMONIA, DIABETES, PREGNANT, INTUBED, ICU, IS_DEAD, entre otras.
- **Nominales:** USMER, MEDICAL_UNIT, PATIENT_TYPE, MONTH_DIED.
- **Especiales:** DATE_DIED, CLASIFICACION_FINAL.



Datos Faltantes

Variables como INTUBED e ICU tienen ~80% de datos faltantes (código 97), limitando su uso directo como predictores de gravedad.

Desbalanceo de Clases

Existe un desbalanceo en variables objetivo (mortalidad, ingreso a UCI), evidente en DATE_DIED (mayoría de '9999-99-99' para supervivencia).

Propósito del Dataset y Objetivo General

El dataset está diseñado para un problema de clasificación supervisada binaria: predecir el riesgo de mortalidad en pacientes con COVID-19.

Variable Objetivo

Se creó la variable binaria **IS_DEAD** a partir de **DATE_DIED**:

- **Clase 0:** Pacientes que sobrevivieron (**DATE_DIED** = '9999-99-99')
- **Clase -1:** Pacientes que fallecieron (**DATE_DIED** = fecha válida)

Esto permite entrenar algoritmos de aprendizaje automático para identificar patrones asociados con desenlaces fatales.

Objetivo General:

Desarrollar un modelo predictivo basado en Random Forest para estimar el riesgo de mortalidad en pacientes con COVID-19, identificando tempranamente a individuos con mayor probabilidad de desenlaces fatales.



Justificación del Estudio: Impacto y Relevancia

La predicción temprana de la mortalidad es crucial en emergencias sanitarias. Este estudio, basado en un amplio registro latinoamericano, ofrece herramientas valiosas.



Importancia Clínica

Permite la identificación temprana de pacientes de alto riesgo, facilitando la priorización de recursos hospitalarios y el diseño de estrategias preventivas.



Relevancia Académica

El dataset permite analizar factores de comorbilidad y evaluar el desempeño de algoritmos con datos reales, ruidosos y desbalanceados.



Impacto Social

Ayuda a comprender los factores de riesgo y apoya la generación de políticas públicas basadas en evidencia para futuras crisis sanitarias.

Preprocesamiento de los Datos

Antes de entrenar el modelo, se realizaron pasos críticos para preparar el dataset, incluyendo ingeniería de características, tratamiento de valores faltantes y transformación de variables.

01

Preparación Previa


Se generaron las variables objetivo 'is_dead' (binaria) y 'month_died' (temporal) a partir de 'DATE_DIED', facilitando el entrenamiento supervisado.

U	V	W
ICU	IS_DEAD	MONTH_DIED
3	97	-1
5	97	-1
3	2	-1
7	97	-1
3	97	-1
3	2	0
3	97	0
3	97	0
3	2	0
3	97	0
3	2	0
3	97	0
3	2	0
3	2	0
3	2	0

02

Tratamiento de Valores Faltantes

Los códigos 97, 98, 99 se convirtieron a NaN y se imputaron usando la moda (variables nominales) o la media (numéricas) con los filtros NumericCleaner y ReplaceMissingValues.



03

Transformación de Categorías

Variables categóricas numéricas se convirtieron a tipo Nominal (NumericToNominal) y luego a variables dummy usando codificación One-Hot (NominalToBinary).



04

Balanceo de Datos

Se aplicó submuestreo aleatorio (SpreadSubsample) para equilibrar el severo desbalance de clases (93% sobrevivientes vs. 7% fallecidos), logrando una distribución 50/50.



Selección del Clasificador: Random Forest

Random Forest fue elegido como clasificador principal por su robustez y eficacia en problemas de clasificación binaria con datos estructurados y desbalanceados.



Naturaleza del Problema

Ideal para clasificación binaria con datos tabulares estructurados, superando a menudo a otros modelos complejos.



Robustez ante Desbalanceo

Permite ajustar `class_weight` para penalizar errores en la clase minoritaria (fallecimientos), mitigando el desbalanceo severo.



Tolerancia a Datos Faltantes

Maneja eficientemente valores faltantes mediante imputación por proximidad y división subrogada.



Control del Sobreajuste

La combinación de múltiples árboles decorrelacionados reduce la varianza y mejora la generalización del modelo.

Justificación Académica

Random Forest ha demostrado superioridad empírica en datos tabulares médicos y excelente manejo de datos desbalanceados, como lo demuestran estudios de Breiman (2001) y Fernández-Delgado et al. (2014).

Primera Ejecución del Modelo y Evaluación

Se realizó una primera ejecución con Random Forest para establecer una línea base, utilizando una división 80/20 del dataset.

Entrenamiento del Modelo

Se utilizó un modelo **Random Forest** con 100 estimadores y `random_state=42` para reproducibilidad. Este enfoque permite establecer una línea base antes de optimizaciones.

```
modelo_v1 = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)
modelo_v1.fit(X_train_80, y_train_80)
```

Resultados Obtenidos

- Registros de Entrenamiento: 123,107
- Registros de Prueba: 30,777
- Accuracy: 0.8988 (89.88%)**

Una exactitud cercana al 90% es consistente con un dataset fuertemente desbalanceado, donde el modelo predice correctamente la mayoría de los casos de la clase mayoritaria.

❏ En datasets desbalanceados, una alta exactitud por sí sola no garantiza una buena detección de la clase crítica (fallecidos). Se requieren métricas por clase (Recall, Precision, F1-score) para una evaluación completa.

Evaluación Detallada: Matriz de Confusión

La matriz de confusión de la primera ejecución (80/20) revela un desempeño sólido y equilibrado, gracias al balanceo de datos previo.


Aciertos (Diagonal Principal)

- **Verdaderos Negativos:** 14,108 sobrevivientes correctamente identificados.
- **Verdaderos Positivos:** 13,553 fallecidos correctamente identificados. Un resultado muy positivo para la clase crítica.

Errores (Diagonal Secundaria)

- **Falsos Positivos:** 1,212 pacientes predichos como fallecidos que sobrevivieron (error "menos grave").
- **Falsos Negativos:** 1,904 pacientes predichos como sobrevivientes que fallecieron (error a minimizar).

El modelo muestra una Exactitud global del 90% y una sensibilidad (Recall) para la clase de fallecidos cercana al 88%, validando la eficacia de Random Forest y el balanceo de datos.



Análisis de Componentes Principales (PCA) - Parte 1

El Análisis de Componentes Principales (PCA) es una técnica estadística que simplifica la complejidad de los datos al transformar un conjunto de variables correlacionadas en un nuevo conjunto de variables no correlacionadas, llamadas componentes principales. Su objetivo es capturar la máxima varianza posible de los datos originales con un número reducido de dimensiones.

Fundamentos Matemáticos Clave

1. Centrado de Datos

Se resta la media de cada característica para centrar los datos alrededor del origen, facilitando el cálculo de la covarianza.

2. Matriz de Covarianza

Se calcula la matriz de covarianza, que describe la relación y variabilidad entre pares de variables en el dataset.

3. Descomposición Espectral

Se realiza una descomposición de valores y vectores propios de la matriz de covarianza para identificar las direcciones de máxima varianza.

4. Selección de Componentes

Se ordenan los valores propios de mayor a menor y se seleccionan los k componentes principales con mayor varianza explicada.

5. Proyección

Los datos originales se transforman al nuevo espacio dimensional definido por los k componentes principales seleccionados.

Aplicación al Dataset COVID-19

Para la aplicación de PCA al dataset de COVID-19, se seleccionaron 19 variables relevantes, excluyendo aquellas de naturaleza temporal o el objetivo (fallecido/sobreviviente). Esta selección se realizó para enfocar el análisis en factores clave del paciente y su condición.

A continuación, se presenta un resumen de algunas variables clave utilizadas:

#	Variable	Tipo	Descripción
1	USMER	Categórica	Nivel de atención médica (público/privado)
2	MEDICAL_UNIT	Categórica	Código de la institución médica
3	SEX	Binaria	Género del paciente
7	AGE	Numérica	Edad del paciente
19	ICU	Binaria	Ingreso a Unidad de Cuidados Intensivos (UCI)

Se implementaron estrategias para el manejo de valores faltantes en las variables seleccionadas, asegurando la integridad de los datos para el análisis de PCA. A continuación, se detallan algunas de las variables y su tratamiento:

Variable	Valores especiales	Estrategia	Resultado
INTUBED	97, 99	Imputación por moda	Transformado a binario (Sí/No)
AGE	N/A	Imputación por mediana	Mantenido como numérico
ICU	97, 99	Imputación por moda	Transformado a binario (Sí/No)

El conjunto de datos procesado para PCA incluye un total de **1,048,575** instancias de pacientes.



Análisis de Componentes Principales (PCA) - Parte 2

Análisis de Varianza Explicada

El primer componente principal (PC1) emerge como el más significativo, explicando un 43.72% de la varianza total de los datos. Esta alta concentración de información en PC1 resalta su importancia en la captura de la estructura fundamental del dataset.

Componente	Varianza Individual	Varianza Acumulada
PC1	43.72%	43.72%
PC2	15.28%	59.00%
PC3	9.00%	68.00%
PC4	5.50%	73.50%
PC5	3.80%	77.30%
...	...	...
PC10	1.20%	89.50%
PC11	1.00%	90.50%
PC12	0.80%	91.30%
PC13	0.64%	91.94%

Para retener el 80% de la varianza se requieren 7 componentes, el 90% requiere 10 componentes, y el 95% de la varianza explicada se logra con 13 componentes.

Experimentos con Diferentes Números de Componentes

Se realizaron pruebas con el modelo Random Forest ajustado para diferentes configuraciones de componentes principales:

N° Componentes	Varianza Explicada	F1-score	Tiempo (segundos)
12	94.94%	0.7294	1.8
10	90.50%	0.7288	1.6
8	83.20%	0.7251	1.4
6	79.10%	0.7197	1.2
4	71.00%	0.7012	1.0

Configuración Óptima

La configuración óptima se alcanzó con **12 componentes principales**. Esta elección permite explicar el 94.94% de la varianza total de los datos originales, manteniendo un alto F1-score de 0.7294, y logrando una reducción del 36.8% en la dimensionalidad original (de 19 a 12 variables).

Componente	Varianza Explicada e Interpretación (ejemplos)
PC1 (43.72%)	Edad, comorbilidades respiratorias (neumonía, EPOC)
PC2 (15.28%)	Tipo de unidad médica, ingreso a UCI
PC3 (9.00%)	Comorbilidades metabólicas (diabetes, obesidad)
PC4 (5.50%)	Síntomas generales (fiebre, tos, dolor de garganta)
PC5 (3.80%)	Comorbilidades cardiovasculares (hipertensión, enfermedad cardíaca)
...	Capturan patrones menos dominantes pero relevantes
PC12 (0.80%)	Contribuciones marginales pero importantes para la varianza

Impacto en el Modelo Predictivo

Reducción Dimensional

Disminuye el número de características de 19 a 12, simplificando el modelo y acelerando el entrenamiento.

Eliminación Multicolinealidad

Los componentes son ortogonales, resolviendo problemas de multicolinealidad entre variables originales.

Mejora de Eficiencia

Permite un uso más eficiente de recursos computacionales sin sacrificar significativamente el rendimiento predictivo.

Reducción de Ruido

Al enfocarse en las dimensiones de mayor varianza, se mitiga el efecto de ruido presente en las variables originales.



Aprendizaje No Supervisado: K-Means Clustering

Para explorar la estructura interna de los datos del dataset COVID-19 sin depender de la variable objetivo, se aplicó la técnica de clustering no supervisado **K-Means**. Este enfoque nos permitió identificar patrones y agrupar a los pacientes en segmentos homogéneos basándose únicamente en sus características clínicas y demográficas.

Análisis No Supervisado Realizado

Variables Utilizadas

Se seleccionaron 12 variables consideradas las más relevantes para el análisis, excluyendo aquellas que pudieran introducir sesgos o ser redundantes. Todas estas variables fueron **previamente escaladas** utilizando **StandardScaler** para asegurar que ninguna característica dominara el proceso de clustering debido a su escala original.

- AGE (Edad)
- DIABETES (Diabetes)
- HIPERTENSION (Hipertensión)
- OBESITY (Obesidad)
- COPD (Enfermedad Pulmonar Obstructiva Crónica)
- ASTHMA (Asma)
- CARDIOVASCULAR (Enfermedad Cardiovascular)
- RENAL_CHRONIC (Enfermedad Renal Crónica)
- TOBACCO (Tabaquismo)
- SEX (Género)
- PATIENT_TYPE (Tipo de Paciente: ambulatorio/hospitalizado)
- USMER (Nivel de atención médica)

Selección del Número de Clusters (K)

Para determinar el número óptimo de clusters (K), se aplicó el **Método del Codo (Elbow Method)**. Este análisis reveló un punto de inflexión claro, sugiriendo que el número más adecuado de agrupaciones es **K = 3**.

Resultados del Clustering

Cluster 1: "Pacientes Jóvenes y Sanos" (43%) Edad promedio: 28 años • Bajas comorbilidades • Mayoría ambulatorios • Mortalidad muy baja Este grupo representa el segmento de menor riesgo frente al COVID-19.	Cluster 2: "Adultos con Comorbilidades Moderadas" (37%) Edad promedio: 45 años • Diabetes o hipertensión presentes con frecuencia • Mezcla de pacientes ambulatorios y hospitalizados Este grupo se clasifica como de riesgo intermedio.	Cluster 3: "Pacientes Geriátricos Críticos" (20%) Edad promedio: 63+ años • Alta prevalencia de múltiples comorbilidades (diabetes, hipertensión, obesidad, enfermedad renal crónica) • Alto porcentaje de hospitalización e ingreso a UCI Este cluster coincide con el grupo de mayor riesgo y mortalidad.
--	---	--

Utilidad del Análisis No Supervisado y Conclusiones

El clustering no solo segmentó la población de pacientes de manera significativa, sino que también aportó valiosa información para comprender mejor la heterogeneidad de la enfermedad.

- ➔ **Identificar patrones ocultos:** Revela estructuras inherentes en los datos que no son evidentes a primera vista.

➔ **Validar perfiles de riesgo:** Verificando si los grupos de riesgo identificados se alinean con la mortalidad real del dataset.
- ➔ **Descubrir subgrupos clínicos relevantes:** Permite agrupar pacientes con características similares antes de aplicar modelos supervisados.

➔ **Complementar el análisis predictivo:** Ayudando a interpretar mejor los factores de riesgo y a diseñar estrategias de intervención más focalizadas.

Los tres clusters detectados en este análisis **se alinean sorprendentemente bien** con estudios clínicos reales sobre la **progresión del COVID-19** y sus **grupos de riesgo**, validando la coherencia y robustez de nuestro dataset y los resultados obtenidos. Esta validación subraya el potencial del aprendizaje no supervisado para generar hipótesis clínicas y refinar modelos predictivos.